




Universidad Veracruzana
Facultad de Estadística e
Informática
Licenciatura en Ingeniería en
Ciencia de Datos



Metodología de la Investigación

Docente:

Lorena López Lozada

Aplicación de CRISP-DM

21 de septiembre de 2026

Integrantes:

Alonso Limon
Zurizaday

Osorio Morales
Jeane Anady

Contenido

1. Comprensión del negocio o problema	4
Contexto del dominio	4
Criterios de éxito del proyecto	4
Recursos y riesgos	5
2. Comprensión de los datos	5
Diccionario de variables principal	6
3. Preparación de los datos	6
4. Modelado o análisis	7
5. Evaluación	9
Limitaciones del análisis	11
6. Despliegue o implementación	11
Conclusión	12
Referencias	13

Resumen

El presente trabajo aplica la metodología CRISP-DM para analizar empíricamente la existencia de la ventaja de localía en la NBA. Utilizando un conjunto de datos histórico de 26,523 partidos disputados entre las temporadas 2003 y 2022, se contrastó el rendimiento estadístico de los equipos jugando en casa frente a su desempeño como visitantes. Mediante pruebas t pareadas y una prueba binomial, los resultados demostraron que los equipos locales ganan el 58.92% de los encuentros, presentando superioridad estadísticamente significativa en puntos anotados (+2.82), porcentaje de tiros de campo, triples, rebotes y asistencias. Se concluye que, si bien la localía ofrece una ventaja sistémica y comprobable, su magnitud es moderada, sugiriendo la intervención de variables externas (como la fatiga por viajes o días de descanso) en el desenlace de los partidos.

1. Comprensión del negocio o problema

El objetivo es analizar si jugar como local representa una ventaja en los partidos de la NBA.

Se compararon:

- Puntos.
- Porcentaje de tiros de campo.
- Porcentaje de tiros libres.
- Porcentaje de triples.
- Asistencias.
- Rebotes.
- Proporción de victorias locales y visitantes.

Contexto del dominio

En el baloncesto profesional, la ventaja de localía es un fenómeno ampliamente discutido.

Factores como la fatiga acumulada por los desplazamientos, el impacto psicológico de la afición local y las particularidades del calendario pueden influir directamente en el rendimiento de los jugadores y en las decisiones arbitrales.

Criterios de éxito del proyecto

- Desde la perspectiva del negocio/deporte: El análisis se considerará exitoso si logra cuantificar claramente si jugar de local incrementa la proporción de victorias en al menos un 5% respecto al porcentaje base del 50%, y si identifica en qué métricas del juego (puntos, rebotes, tiros) radica la principal diferencia.
- Desde la perspectiva técnica: Se establece un nivel de significancia estadística de $\alpha = 0.05$ para rechazar o no rechazar las hipótesis nulas durante las pruebas inferenciales.

Recursos y riesgos

Para el desarrollo se utilizó el lenguaje Python, empleando las bibliotecas Pandas para la manipulación de datos y SciPy para el contraste de hipótesis. El principal riesgo identificado en los datos es la inclusión de la temporada 2019-2020, donde los partidos se jugaron en una sede neutral y sin público, lo cual introduce un sesgo atípico en la medición tradicional de la localía.

2. Comprensión de los datos

La base original contiene:

- 26,651 registros.
- 21 variables.
- Temporadas de 2003 a 2022.
- Todos los partidos aparecen con estado Final.
- 99 partidos tienen valores faltantes en sus estadísticas.
- Existen 29 identificadores GAME_ID repetidos.
- Las variables HOME_TEAM_ID y TEAM_ID_home contienen la misma información.
- Las variables VISITOR_TEAM_ID y TEAM_ID_away también son equivalentes.

La variable HOME_TEAM_WINS indica el resultado:

- 1: ganó el equipo local.
- 0: ganó el equipo visitante.

Diccionario de variables principal

Para estandarizar el análisis, se aislaron las variables más representativas del rendimiento del equipo, cuyas descripciones son las siguientes:

- **GAME_ID:** (Categórica) Identificador único del partido.
- **GAME_DATE_EST:** (Fecha) Fecha en la que se disputó el encuentro.
- **HOME_TEAM_WINS:** (Binaria) Indicador de victoria; 1 si ganó el local, 0 si ganó el visitante.
- **PTS_home / PTS_away:** (Numérica) Puntos totales anotados por el equipo local y visitante, respectivamente.
- **FG_PCT_home / FG_PCT_away:** (Numérica) Porcentaje de efectividad en tiros de campo.
- **AST_home / AST_away:** (Numérica) Total de asistencias registradas por equipo.
- **REB_home / REB_away:** (Numérica) Total de rebotes capturados por equipo.

3. Preparación de los datos

Se realizó lo siguiente:

1. Convertir GAME_DATE_EST a formato de fecha.
2. Identificar los partidos repetidos mediante GAME_ID.
3. Conservar un solo registro por partido.
4. Limpieza de ruido y redundancia: Se procedió a eliminar los 99 registros con estadísticas faltantes y los 29 identificadores duplicados para garantizar la independencia de las

observaciones y evitar que registros corruptos alteraran el cálculo de las medias. Asimismo, se descartaron las columnas de identificación redundantes para optimizar el procesamiento en memoria.

6. Crear variables con las diferencias entre local y visitante:

$$\text{Diferencia de puntos} = PTShome - PTSaway$$

El mismo procedimiento se aplica a porcentajes de tiro, asistencias y rebotes. Después de la limpieza quedan:

- 26,523 partidos completos y únicos.

Para estandarizar la comparativa, se realizó ingeniería de características calculando la diferencia directa entre local y visitante para cada partido i , aplicando las siguientes fórmulas:

- $\Delta Puntos_i = PTS_home_i - PTS_away_i$
- $\Delta Tiros\ de\ Campo_i = FG_PCT_home_i - FG_PCT_away_i$
- *Este mismo principio matemático se aplicó univariadamente a los rebotes, asistencias y tiros libres.*

4. Modelado o análisis

Planteamiento formal de hipótesis

Para validar rigurosamente las diferencias observadas, se planteó el siguiente sistema de hipótesis para la prueba t de Student para muestras pareadas:

- **Hipótesis Nula (H_0):** La diferencia media entre el rendimiento del equipo local y el visitante es igual a cero ($\mu_{local} - \mu_{visitante} = 0$).

- **Hipótesis Alternativa (H_1):** La diferencia media entre el rendimiento del equipo local y el visitante es distinta de cero ($\mu_{local} - \mu_{visitante} \neq 0$).

Estadística	Local	Visitante	Diferencia
Puntos	103.45	100.63	+2.82
Tiros de campo	46.08 %	44.97 %	+1.10 puntos
Tiros libres	76.04 %	75.88 %	+0.16 puntos
Triples	35.61 %	34.95 %	+0.66 puntos
Asistencias	22.82	21.49	+1.33
Rebotes	43.37	42.11	+1.26

5. Evaluación

Los resultados muestran que los equipos locales presentan valores promedio superiores en casi todas las estadísticas.




Figura 1. Comparación de promedios entre equipos locales y visitantes

Los equipos locales anotaron 2.82 puntos más por partido. También mostraron ventajas promedio en tiros de campo, triples, asistencias y rebotes.

- Los locales ganaron **15,628 partidos**.
- Los visitantes ganaron **10,895 partidos**.
- La proporción de victorias locales fue de **58.92 %**.
- Las diferencias en puntos, tiros de campo, triples, asistencias y rebotes fueron estadísticamente significativas.
- La diferencia en tiros libres no fue significativa, con un valor aproximado de $p = 0.067$.

Aunque las diferencias son significativas por la gran cantidad de partidos, su magnitud es relativamente pequeña. Por eso, la localía parece ofrecer una ventaja real, pero no garantiza la victoria.

Resultados de victorias

En los 26,523 partidos analizados, los equipos locales ganaron 15,628 encuentros (58.92%) y los visitantes ganaron 10,895 (41.08%). La prueba binomial produjo un p valor menor que 0.001, por lo que la proporción de victorias locales es estadísticamente diferente de 50%.




Figura 2. Porcentaje de victorias locales y visitantes

Contraste con los criterios de éxito

El proyecto cumplió con los criterios de éxito planteados en la Fase 1. Se comprobó que el porcentaje de victorias como local (58.92%) supera con creces el umbral del 5% extra sobre una probabilidad equilibrada del 50%. A nivel técnico, todas las métricas principales (salvo los tiros libres) arrojaron un valor $p < 0.05$, permitiendo rechazar la hipótesis nula de igualdad.

Limitaciones del análisis

Es importante señalar que el modelo actual tiene limitaciones descriptivas. No toma en cuenta variables de contexto temporal como los días de descanso entre partidos, la distancia recorrida en los viajes por el equipo visitante, las lesiones de jugadores estrella, ni las variaciones de rendimiento a través de las diferentes eras del baloncesto moderno (2003 frente a 2022).

6. Despliegue o implementación

La implementación se realizó en Google Colab con Python. Se utilizaron pandas para la lectura y preparación, SciPy para las pruebas estadísticas y Matplotlib para las visualizaciones. El cuaderno genera una base limpia, una tabla de comparación, un resumen por temporada y las gráficas del análisis.

El resultado puede utilizarse en una presentación, un reporte académico o como punto de partida para estudios posteriores. Si se desea construir un modelo predictivo, la variable HOME_TEAM_WINS podría emplearse como objetivo en una regresión logística, un árbol de decisión u otro clasificador; esa ampliación no forma parte del análisis actual.

Plan de mantenimiento y trabajos futuros Para garantizar la continuidad del proyecto, se propone un ciclo de actualización anual al finalizar cada temporada regular de la NBA, integrando los nuevos registros al repositorio base. Como fases futuras, los hallazgos de este análisis exploratorio fundamentarán la creación de un modelo de *Machine Learning* (como Regresión Logística o Random Forest) que incluya variables de calendario para predecir la probabilidad de victoria de un partido antes de que se juegue, así como el

despliegue de un *Dashboard* interactivo para la visualización de la ventaja de localía segmentada por estadio y equipo.

Conclusión

La aplicación de CRISP-DM permitió organizar el proyecto desde la pregunta inicial hasta la presentación de resultados. El análisis indica que existe una ventaja de localía en la NBA. Los equipos locales ganaron aproximadamente el 58.9 % de los partidos y obtuvieron mejores promedios en puntos, tiros de campo, triples, asistencias y rebotes. La diferencia más clara fue de aproximadamente 2.82 puntos por partido a favor del equipo local. Sin embargo, la magnitud de las diferencias es pequeña, por lo que otros factores también intervienen en el resultado.

Referencias

Harris, C. R., Millman, K. J., van der Walt, S. J., et al. (2020). Array programming with NumPy. *Nature*, 585(7825), 357–362. <https://doi.org/10.1038/s41586-020-2649-2>

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90-95.

McKinney, W. (2010). Data Structures for Statistical Computing in Python. *Proceedings of the 9th Python in Science Conference*, 51-56.

Virtanen, P., Gommers, R., Oliphant, T. E., et al. (2020). SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, 17(3), 261-272.